

Zusammenfassung zum Vortrag zur Bachelorarbeit zum Thema „Regularization of Neural Networks for Natural Language Processing“ von Dayyan Smith von Korbinian Schmidhuber

Ziel der Bachelorarbeit von Dayyan Smith ist es, den Effekt von Regularization eines Neuralen Netzwerkes auf Stance-Klassifikation. Er beschäftigt sich im Rahmen der Arbeit mit der sogenannten „Fake News Challenge“, in der es darum geht zu erforschen, inwieweit künstliche Intelligenz dazu benutzt werden kann, um Fake News zu erkennen.

Die erste Phase dieser Fake News Challenge ist die Erkennung der sogenannten Stance. Diese bezeichnet, ob zwei Texte sich nicht widersprechen (Kategorie: agree), widersprechen (disagree), es nicht eindeutig festzustellen ist (discuss), oder ob die zwei Texte nichts miteinander zu tun haben (unrelated).

Dayyan zeigt anhand verschiedener Beispiele, wie schwer es – selbst für Menschen – sein kann, eine solche Stance für zwei Texte einzuordnen.

Als nächstes stellt Dayyan das Encoding vor: Für jedes Wort in einer Überschrift (Text 1) und einem dazugehörigem Textkörper (Text 2), wird mit dem word2vec Tool ein Vektor erstellt. All diese Wörter werden in das Neuronale Netzwerk eingefügt, was eine Repräsentation für jeden Satz ergibt.

Anschließend werden die beiden Texte (Überschrift und Textkörper) miteinander konkateniert.

Die Architektur des Neuronalen Netzwerkes besteht aus 2 Hidden Layers, in die die konkatenierten Texte eingegeben werden. Die konkatenierten Texte sowie die Ergebnisse der beiden Hidden Layers werden zusammengefasst und ergeben den Classification-Layer.

Allerdings kann man mit genügend Parametern jedes Datenset passend machen in einer solchen Klassifikation. Die Kunst besteht darin, auch auf neuen, unbekannten Daten anschließend gute Ergebnisse zu erzielen. Durch Regularization soll das Ergebnis, das eine solche Klassifikation auf unbekannten Daten erreicht, verbessert werden.

Dayyan testet im Rahmen seiner Arbeit drei verschiedene Regularization-Methoden: L1 Regularization, L2 Regularization und Dropout Regularization.

Bei der Dropout Regularization werden nicht die Kostenfunktionen selbst modifiziert, sondern das Model selbst. Es werden paar der Neuronen aus dem Netzwerk rausgeworfen, das Model trainiert, die Neuronen wiederhergestellt und andere Neuronen rausgeworfen. Dies wird mehrmals wiederholt. Diese Wiederholungen helfen dabei, dass die Neuronen nicht von einem bestimmten Neuron abhängig werden.

Bei der Evaluation kam Dayyan zu dem Schluss dass bei seinen Tests die L1 Regularization besser abschnitt als die L2 Regularization. Die Dropout Regularization sei noch am berechnen, wird aber auf eine ähnliche Leistung kommen.